

1. NALOGA

a)

Povprečni dohodek

Populacija je velikosti 43886. Vzamemo enostavni slučajni vzorec 400 enot.

Sledi: $N = 43886, n = 400$.

Naj bo X_k skupni dohodek v k -ti družini.

Torej je povprečni dohodek v Kindergradu:

$$\bar{X} = \frac{X_1 + \dots + X_n}{n}.$$

Standardna napaka

Vemo: $se(\bar{X}) = \sqrt{var(\bar{X})}$. Ker imamo enostavni slučajni vzorec, vemo tudi, da je

$$var(\bar{X}) = \frac{1}{n} \frac{N-n}{N-1} \sigma^2$$

kjer je σ^2 populacijska varjanca. Nepristranska cenilka za σ^2 je

$$\hat{\sigma}^2 = \frac{N-1}{N(n-1)} \sum_{k=1}^n (X_k - \bar{X})^2.$$

Sledi:

$$\widehat{se(\bar{X})} = \sqrt{\frac{1}{n} \frac{N-n}{N(n-1)} \sum_{k=1}^n (X_k - \bar{X})^2}.$$

Interval zaupanja

Iz navodil sledi, da je interval zaupanja enak $\bar{X} \pm 1,96 \cdot se(\bar{X})$.

Končne vrednosti

b)

Če stratificiramo, mora veljati

$$\frac{n_k}{n} = \frac{N_k}{N}, \sum_{k=1}^K n_k = n.$$

V našem primeru stratificiramo po četrtih, torej $k = 4$. Vemo:

$N_1 = 10149$ (*severna četrt*),

$N_2 = 10390$ (*vzgodna četrt*),

$N_3 = 13457$ (*južna četrt*),
 $N_4 = 9890$ (*zahodna četrt*). Če malo obrnemo zgornjo enakost, dobimo

$$n_k = \frac{N_k}{N}n.$$

Izračunamo za $k = 1, 2, 3, 4$ in upoštevamo vrednosti N_1, N_2, N_3, N_4 ter $N = 43886$.

Dobimo:

$$n_1 = \frac{10149}{43886} \cdot 400 = 92,5033 \rightarrow n_1 = 92,$$

$$n_2 = \frac{10390}{43886} \cdot 400 = 94,699 \rightarrow n_2 = 95,$$

$$n_3 = \frac{13457}{43886} \cdot 400 = 122,654 \rightarrow n_3 = 123,$$

$$n_4 = \frac{9890}{43886} \cdot 400 = 90,142 \rightarrow n_4 = 90.$$

Preverimo:

$$\sum_{k=1}^4 n_k = 92 + 96 + 123 + 90 = 400.$$

Naj bo sedaj X_{kj} povprečni dohodek j -te družine v k -tem stratumu.
 Povprečni dohodek družine se sedaj izraža kot:

$$\bar{X} = \frac{1}{n} \sum_{k=1}^{\#stratumov} \sum_{j=1}^{n_k} X_{kj}.$$

Standarna napaka $se(\bar{X}) = \sqrt{var(\bar{X})}$:

$$var(\bar{X}) = \sum_k w_k^2 var(\bar{X}_k) = \sum_k w_k^2 \cdot \frac{\hat{\sigma}_k^2}{n_k} \cdot \frac{N_k - n_k}{N_k - 1},$$

kjer je $w_k = \frac{N_k}{N}$ delež, σ_k^2 pa populacijska varjanca v k -tem stratumu. Torej:

$$\hat{\sigma}_k^2 = \frac{N_k - 1}{N_k(n_k - 1)} \sum_{j=1}^{n_k} (X_{kj} - \bar{X}_k)^2,$$

kjer je \bar{X}_k povprečje k -tega stratuma.

Interval zaupanja: $\bar{X} \pm 1,96 \cdot se(\bar{X})$.

Vstavimo podatke in dobimo:

c)

Variance znotraj četrti:

Variance med četrtmi dobimo tako, da izračunamo povprečje dohodka v vsaki četrti, jo primerno obtežimo in izračunamo varjanco. Torej dobimo:

2. NALOGA

a)

Poglavje 7.5.2, stran 30 nam pove da je:

$$\text{var}(\bar{X}_s) \approx \sum_{l=1}^L \frac{W_l^2 \sigma_l^2}{n_l}.$$

Uporabimo izrek (Theorem A) iz poglavja 7.5.3 na strani 232.

Izrek: Velikosti vzorcev n_1, \dots, n_L , ki minimizirajo $\text{var}(\bar{X}_s)$, pri pogoju $n_1 + \dots + n_L = n$, so podane z naslednjo enačbo:

$$n_l = n \frac{W_l \sigma_l}{\sum_{k=1}^L W_k \sigma_k},$$

kjer je $l = 1, \dots, L$.

Od tod direktno sledi, da so naše minimalne vrednosti:

$$n_i = n \frac{W_i \sigma_i}{\sum_{l=1}^L W_l \sigma_l}$$

b)

Ta del naloge je podoben a) primeru, le da je naš začetni pogoj drugačen. Zato sledimo dokazu zgornjega izreka, le da spremenimo pogoj. Dokaz je na strani 233, poglavje 7.5.3.

Uporabimo tako imenovani vezani ekstrem ali Lagrangev multiplikator.

$$L(n_1, \dots, n_K, \lambda) = \sum_{k=1}^K \frac{W_k^2 \sigma_k^2}{n_k} + \lambda \left(C_0 + \sum_{k=1}^K n_k C_k - C \right)$$

Iščemo ekstreme, zato parcialno odvajamo L .

$$\frac{\partial L}{\partial n_k} = -\frac{W_k \sigma_k^2}{n_k^2} + \lambda C_k,$$

za $k = 1, 2, \dots, K$.

Vse parcialne odvode enačimo z 0 in dobimo:

$$n_k = \frac{W_k \sigma_k}{\sqrt{\lambda C_k}}$$

Vemo: $n = n_1 + \dots + n_K$. Torej:

$$n = \sum_{k=1}^K n_k = \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{\lambda C_k}} = \frac{1}{\sqrt{\lambda}} \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{C_k}}$$

Sledi:

$$\sqrt{\lambda} = \frac{1}{n} \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{C_k}}$$

Končno sledi:

$$n_k = \frac{n W_k \sigma_k}{\sqrt{C_k} \sum_{i=1}^K \frac{W_i \sigma_i}{\sqrt{C_i}}}$$

c)

V tem primeru želimo minimizirati stroške. Torej bomo zapisali vezani ekstrem za stroške raziskave, pri predpisani natančnosti. Torej:

$$L(n_1, \dots, n_K, \lambda) = C_0 + \sum_{k=1}^K C_k n_k + \lambda \sum_{k=1}^K \frac{W_k^2 \sigma_k^2}{n_k}$$

Postopamo kot v prejšnjih točkah:

$$\frac{\partial L}{\partial n_i} = C_i - \lambda \frac{W_i^2 \sigma_i^2}{n_i^2} = 0,$$

za $i = 1, 2, \dots, K$.

Računamo:

$$n_i = \sqrt{\frac{\lambda}{C_i}} W_i \sigma_i.$$

$$n = \sum_{i=1}^K n_i = \sum_{i=1}^K \sqrt{\frac{\lambda}{C_i}} W_i \sigma_i = \sqrt{\lambda} \sum_{i=1}^K \sqrt{\frac{1}{C_i}} W_i \sigma_i$$

$$\sqrt{\lambda} = \frac{n}{\sum_{i=1}^K \sqrt{\frac{1}{C_i}} W_i \sigma_i}$$

Torej:

$$n_i = \frac{n}{\sqrt{C_i} \sum_{j=1}^K \sqrt{\frac{1}{C_j}} W_j \sigma_j} W_i \sigma_i.$$

3.NALOGA

a)

$$X \sim f(x, \alpha) = \begin{cases} \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}, & 0 < x < 1. \\ 0, & \text{šicer.} \end{cases}$$

Vemo:

$$E(X) = \frac{1}{3}, \text{var}(X) = \frac{2}{9(3\alpha + 1)}.$$

Ker je:

$$var(X) = E(X^2) - E(X)^2,$$

sledi:

$$E(X^2) = var(X) + E(X)^2 = \frac{2}{9(3\alpha+1)} + \frac{1}{9} = \frac{\alpha+1}{3(3\alpha+1)}$$

$E(X^2)$ je drugi moment slučajne spremenljivke X , torej:

$$E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Zgornji enačbi izenačimo in poračunamo α :

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\alpha+1}{3(3\alpha+1)}$$

$$\frac{9\alpha+3}{n} \sum_{i=1}^n X_i^2 = \alpha+1$$

$$\frac{9\alpha}{n} \sum_{i=1}^n X_i^2 - \alpha = 1 - \frac{3}{n} \sum_{i=1}^n X_i^2$$

$$\alpha = \frac{1 - \frac{3}{n} \sum_{i=1}^n X_i^2}{\frac{9}{n} \sum_{i=1}^n X_i^2 - 1}$$

b)

$$f_X(x, \alpha) = \begin{cases} \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}, & 0 < x < 1. \\ 0, & \text{šicer.} \end{cases}$$

$$L_1(\alpha|x) = \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}$$

$$L(\alpha|x_1, \dots, x_n) = L_1(\alpha|x_1) \cdot \dots \cdot L_1(\alpha|x_n) = \left(\frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} \right)^n x_1^{\alpha-1} \cdot \dots \cdot x_n^{\alpha-1} (1-x_1)^{2\alpha-1} \cdot \dots \cdot (1-x_n)^{2\alpha-1}$$

$$l(\alpha|x_1, \dots, x_n) = \ln(L(\alpha|x_1, \dots, x_n)) = l_1(\alpha|x_1) + \dots + l_1(\alpha|x_n)$$

$$l_1(\alpha|x) = \ln(L_1(\alpha|x)) = \ln(\Gamma(3\alpha)) - \ln(\Gamma(\alpha)) - \ln(\Gamma(2\alpha)) + (\alpha-1)\ln(x) + (2\alpha-1)\ln(1-x)$$

$$\begin{aligned}
l(\alpha|x) &= \\
\sum_{i=1}^n (\ln(\Gamma(3\alpha)) - \ln(\Gamma(\alpha)) - \ln(\Gamma(2\alpha)) + (\alpha - 1)\ln(x_i) + (2\alpha - 1)\ln(1 - x_i)) \\
\frac{\partial l}{\partial \alpha} &= \sum_{i=1}^n \frac{1}{\Gamma(3\alpha)} \Gamma'(3\alpha) 3 - \frac{1}{\Gamma(\alpha)} \Gamma'(\alpha) - \frac{1}{\Gamma(2\alpha)} \Gamma'(2\alpha) 2 + \ln(x_i) + 2\ln(1 - x_i) \\
\sum_{i=1}^n \frac{1}{\Gamma(3\alpha)} \Gamma'(3\alpha) 3 - \frac{1}{\Gamma(\alpha)} \Gamma'(\alpha) - \frac{1}{\Gamma(2\alpha)} \Gamma'(2\alpha) 2 &= \ln\left(\frac{1}{x_i(1 - x_i)}\right)
\end{aligned}$$

Cenilka obstaja, ko ima zgornja enačba rešitev.
Uporabimo funkcijo digamma in rešimo do konca? no clue.

c)

$$var(\hat{\alpha}) = \frac{1}{nI_1(\hat{\alpha})}.$$

$$I_1(\hat{\alpha}) = -E \left[\frac{\partial^2 l_1(\alpha|x)}{\partial \alpha^2} \right]$$

$$\begin{aligned}
&\frac{\partial^2 l_1(\alpha|x)}{\partial \alpha^2} = \\
&3 \frac{\Gamma''(3\alpha)\Gamma(3\alpha) - \Gamma'(3\alpha)^2}{\Gamma(3\alpha)^2} - \frac{\Gamma''(\alpha)\Gamma(\alpha) - \Gamma'(\alpha)^2}{\Gamma(\alpha)^2} - 2 \frac{\Gamma''(2\alpha)\Gamma(2\alpha) - \Gamma'(2\alpha)^2}{\Gamma(2\alpha)^2} \\
var(\hat{\alpha}) &= \frac{1}{n} \frac{1}{3 \frac{\Gamma''(3\alpha)\Gamma(3\alpha) - \Gamma'(3\alpha)^2}{\Gamma(3\alpha)^2} - \frac{\Gamma''(\alpha)\Gamma(\alpha) - \Gamma'(\alpha)^2}{\Gamma(\alpha)^2} - 2 \frac{\Gamma''(2\alpha)\Gamma(2\alpha) - \Gamma'(2\alpha)^2}{\Gamma(2\alpha)^2}}
\end{aligned}$$

4. NALOGA

Za reševanje te naloge, sem si pomagala s knjigo *Mathematical statistics and data analysis*. Iz poglavja 9.5, na strani 341, izvemo, da če imamo model, kjer so verjetnosti vektorsko porazdeljene in imamo opis za hipotezo H_0 , kjer je $p = p(\theta)$, kjer je θ neznan, je števec za verjetnostno funkcijo enak:

$$\max_{p \in \omega_0} \left(\frac{n!}{x_1! \dots x_m!} \right) p_1(\theta)^{x_1} \dots p_m(\theta)^{x_m},$$

kjer so x_i opazovane vrednosti v m celicah. Maksimum bo dosežen pri:

$$\hat{p}_i = \frac{x_i}{n}.$$

Razmerje verjetij je tako enako:

$$\Lambda = \frac{\frac{n!}{x_1! \dots x_m!} p_1(\hat{\theta})^{x_1} \dots p_m(\hat{\theta})^{x_m}}{\frac{n!}{x_1! \dots x_m!} \hat{p}_1^{x_1} \dots \hat{p}_m^{x_m}}.$$

Poglejmo sedaj naš primer. Podatke imamo podane v razpredelnici za $m = 0, 1, \dots, 12$, $n = \#$ podatkov = 6115. Oprazovane vrednosti x_1, \dots, n_{12} prebermo iz drugega stolpca v tabeli. Računamo po postopku opisanem zgoraj:

$$\max \left(\frac{6115!}{7!45!181! \dots 24!3!} \right) p_1^7 p_2^{45} \dots p_{12}^3$$

Maksimum je torej dosežen pri:

$$\hat{p}_1 = \frac{7}{6115}, \hat{p}_2 = \frac{45}{6115}, \dots, \hat{p}_{12} = \frac{3}{6115},$$

Poračunati moramo še imenovalca ulomka, da bomo dobili razmerje verjetij. Testirati želimo hipotezo, da je število moških potomcev, ki se rodijo v družini z 12 otroci, porazdeljeno binomsko $Bin(12, p)$. Torej je verjetnostna funkcija L enaka:

$$L = \left(\frac{6115!}{7!45!181! \dots 24!3!} \right) ((1-p)^{12})^7 (2p(1-p)^{11})^{45} \dots (p^{12})^3.$$

Izraz logaritmujemo in odvajamo po p , izračunamo maksimum.

$$\frac{\partial l}{\partial p} = 0.$$

Po krajšem izračunu dobimo:

$$\frac{35280}{p} = \frac{38100}{1-p}$$

Tako dobimo:

$$\hat{p} = \frac{35280}{73380} = 0.4807849550286182.$$

Torej po Wilkinsonovem izreku zapišemo:

$$\lambda = 2\ln(\Lambda) = 2l(\hat{p}_0, \dots, \hat{p}_{12}) - 2l(\hat{p})$$

Vstavimo zgoraj poračunane vrednosti:

$$2(7\ln(\hat{p}_1) + 45\ln(\hat{p}_2) \dots 3\ln(\hat{p}_{12})) - 2(7 * 12\ln(1 - \hat{p}) + 45(\ln(12\hat{p}) + 11\ln(1 - \hat{p})) + \dots + 3 * 12\ln(\hat{p}))$$

Ko vstavimo podatke dobimo:

$$\lambda = 97.0065.$$

Wilksov izrek nam pove, da bomo hipotezo zavrnili, če je $\lambda > \chi^2_{1-\alpha}(dim\Omega - dim\Omega_0)$. Dimenziji prostorov sta očitni: $dim\Omega - dim\Omega_0 = 12 - 1 = 11$. Testiramo za $\alpha = 0.01$ in $\alpha = 0.05$. Iz tabele preberemo vrednosti in dobimo:

$$\chi^2_{0.99}(11) = 19.68, \chi^2_{0.95}(11) = 24.72.$$

Vidimo, da sta vrednosti v obeh primerih manjši od λ , zato hipotezo v obeh primerih zavrnemo.

Model bi lahko bil napačen iz več razlogov. Eden bi bil naprimer, da nismo upoštevali vsa rojstva, vendar le preživele otroke. Lahko, da smo zbrali podatke v različnih zgodovinskih obdobjih, katera vplivajo na rojstva otrok (vojna in podobno).

5. NALOGA

Ocen po metodi največjega verjetja

Da bomo vedeli kako so porazdeljeni Y_i -ji, poračunamo njihovo pričakovano vrednost in varjanco.

$$E(Y_i) = E(\beta_0 + \beta_1 x_i + \epsilon_i) = \beta_0 + \beta_1 x_1$$

$$var(Y_i) = \sigma^2$$

Torej so Y_i porazdeljeni $N(\beta_0 + \beta_1 x_1, \sigma^2)$. Dobimo:

$$L_1 = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}}$$

Verjetnostna funkcija je sestavljena iz produktov porazdelitvenih funkcij. Torej dobimo:

$$\log(L) = -n\log(\sigma) - \frac{n}{2}\log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

. Najprej poračunamo za prvi parameter β_0 . Enačbo odvajamo po β_0 in enačimo z 0.

$$\begin{aligned} \frac{\partial}{\partial \beta_0} \log(L) &= \frac{\partial}{\partial \beta_0} (-n\log(\sigma) - \frac{n}{2}\log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2) = \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) \end{aligned}$$

Dobimo:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

Sledi:

$$\sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0$$

Torej je končni rezultat enak:

$$\beta_o = \frac{1}{n} \left(\sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right).$$

Postopek ponovimo za drugi parameter β_1 :

$$\begin{aligned} \frac{\partial}{\partial \beta_1} \log(L) &= \frac{\partial}{\partial \beta_1} (-n \log(\sigma) - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_o - \beta_1 x_i)^2) = \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \beta_o - \beta_1 x_i) \end{aligned}$$

Dobimo:

$$\sum_{i=1}^n x_i (y_i - \beta_o - \beta_1 x_i) = 0.$$

Sledi:

$$\sum_{i=1}^n x_i y_i - \beta_o \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 = 0.$$

Vstavimo vrednost za β_o :

$$\begin{aligned} \sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right) \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 &= 0. \\ \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i - \beta_1 \left(-\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i + \sum_{i=1}^n x_i^2 \right) &= 0. \end{aligned}$$

Torej je končni rezultat enak:

$$\beta_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{-\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i + \sum_{i=1}^n x_i^2}$$

Oziroma:

$$\beta_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}$$

Vstavimo še za β_o :

$$\begin{aligned} \beta_o &= \frac{1}{n} \left(\sum_{i=1}^n y_i - \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \sum_{i=1}^n x_i \right). \\ \beta_o &= \frac{1}{n} \left(\sum_{i=1}^n y_i - \frac{n \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \right). \end{aligned}$$

$$\beta_o = \frac{1}{n} \frac{n \sum_{i=1}^n y_i \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i - n \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i + \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}.$$

Končni rezultat:

$$\beta_o = \frac{\sum_{i=1}^n y_i \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}.$$

Ocena po metodi najmanjših kvadratov

Ker so šumi ϵ_i neodvisni za vsak $i = 1, 2, \dots, n$ in $\epsilon_i \sim N(0, \sigma^2)$ lahko uporabimo izrek Gauss-Markova za ocene parametrov β_0 in β_1 . Imamo:

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Po izreku Gauss-Markova vemo da je najboljša cenilka za $\beta = (X^T X)^{-1} X^T Y$. Računamo:

$$\begin{aligned} & \left(\begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \\ & = \left(\begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \right)^{-1} \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{bmatrix} = \\ & = \frac{1}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \begin{bmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{bmatrix} \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{bmatrix} = \\ & = \frac{1}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \begin{bmatrix} \sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i - \sum_{i=1}^n x_i \sum_{i=1}^n x_i y_i \\ -\sum_{i=1}^n x_i \sum_{i=1}^n y_i + n \sum_{i=1}^n x_i y_i \end{bmatrix} \end{aligned}$$

Zgornjo vrstico primerjamo z β_0 , ki smo jo dobili po metodi največjega verjetja, spodnjo pa z β_1 . Vidimo, da sta enaki.