

# **POROČILO SEMINARSKE NALOGE**

MARUŠA ORAŽEM

Matematika  
Fakulteta za matematiko in fiziko  
July 12, 2020

# 1. NALOGA

Koda se nahaja v datoteki PrvaNaloga.ipynb, kjer so poračunane vrednosti za spodnje primere. Pomagala sem si z knjižnico scipy.

a)

Iz datoteke PrvaNaloga.ipynb preberemo:

Ocena povprečnega dohodka v Kibergradu, glede na enostavno slučajno vzorčenje je 42942.15.

Standardna napaka: 1593.0009644380311.

Interval zaupanja: [39819.86810970146, 46064.43189029854].

b)

Če stratificiramo, mora veljati

$$\frac{n_k}{n} = \frac{N_k}{N}, \sum_{k=1}^k n_k = n.$$

V našem primeru stratificiramo po četrtih, torej  $k = 4$ . Vemo:

$N_1 = 10149$  (*severna četrt*),

$N_2 = 10390$  (*vzgodna četrt*),

$N_3 = 13457$  (*južna četrt*),

$N_4 = 9890$  (*zahodna četrt*). Če malo obrnemo zgornjo enakost, dobimo

$$n_k = \frac{N_k}{N} n.$$

Izračunamo za  $k = 1, 2, 3, 4$  in upoštevamo vrednosti  $N_1, N_2, N_3, N_4$  ter  $N = 43886$ .

Dobimo:

$$n_1 = \frac{10149}{43886} \cdot 400 = 92,5033 \rightarrow n_1 = 92,$$

$$n_2 = \frac{10390}{43886} \cdot 400 = 94,699 \rightarrow n_2 = 95,$$

$$n_3 = \frac{13457}{43886} \cdot 400 = 122,654 \rightarrow n_3 = 123,$$

$$n_4 = \frac{9890}{43886} \cdot 400 = 90,142 \rightarrow n_4 = 90.$$

Preverimo:

$$\sum_{k=1}^4 n_k = 92 + 96 + 123 + 90 = 400.$$

Povprečje in standardno napako računamo po stratumih in jih primerno obtežimo, da dobimo skupno povprečje in standardno napako.

Interval zaupanja:  $\bar{X} \pm 1,96 \cdot se(\bar{X})$ .

Vstavimo podatke in dobimo:

Ocena povprečja dohodka, če stratificiramo: 41215.59575702422.

Standarna napaka, če stratificiramo: 16269.87055983993.

Interval zaupanja, če stratificiramo: [9326.649459737953, 73104.54205431048].

Vidimo, da je standardna napaka v tem primeru veliko večja, zato rečemo, da se ne splača stratificirati.

c)

Variance znotraj četrti:

Prva: 1207934484.6014097,

Druga: 647823289.4396416,

Tretja: 962434398.3292009,

Četrta: 1035070492.6067415.

Variance med četrtmi dobimo tako, da izračunamo povprečje dohodka v vsaki četrti, jo primerno obtežimo in izračunamo varjanco. Torej dobimo:

Varianca med četrtmi: 2162215.4374019047.

## 2. NALOGA

a)

Za rešitev te naloge, sem si pomagala s knjigo *John A. Rice: Mathematical Statistic and Data Analysis*. Poglavje 7.5.2, stran 230, nam pove da je:

$$var(\bar{X}_s) \approx \sum_{l=1}^L \frac{W_l^2 \sigma_l^2}{n_l}.$$

Uporabimo izrek (Theorem A) iz poglavja 7.5.3 na strani 232.

**Izrek:** Velikosti vzorcev  $n_1, \dots, n_L$ , ki minimizirajo  $var(\bar{X}_s)$ , pri pogoju  $n_1 + \dots + n_L = n$ , so podane z naslednjo enačbo:

$$n_l = n \frac{W_l \sigma_l}{\sum_{k=1}^L W_k \sigma_k},$$

kjer je  $l = 1, \dots, L$ .

Od tod direktno sledi, da so naše minimalne vrednosti:

$$n_i = n \frac{W_i \sigma_i}{\sum_{l=1}^K W_l \sigma_l}$$

b)

Ta del naloge je podoben a) primeru, le da je naš začetni pogoj drugačen. Zato sledimo dokazu zgornjega izreka, le da spremenimo pogoj. Dokaz je na strani

233, poglavje 7.5.3.

Uporabimo tako imenovani vezani ekstrem ali Lagrangev multiplikator.

$$L(n_1, \dots, n_K, \lambda) = \sum_{k=1}^K \frac{W_k^2 \sigma_k^2}{n_k} + \lambda \left( C_0 + \sum_{k=1}^K n_k C_k - C \right)$$

Iščemo ekstreme, zato parcialno odvajamo L.

$$\frac{\partial L}{\partial n_k} = -\frac{W_k \sigma_k^2}{n_k^2} + \lambda C_k,$$

za  $k = 1, 2, \dots, K$ .

Vse parcialne odvode enačimo z 0 in dobimo:

$$n_k = \frac{W_k \sigma_k}{\sqrt{\lambda C_k}}$$

Vemo:  $n = n_1 + \dots + n_K$ . Torej:

$$n = \sum_{k=1}^K n_k = \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{\lambda C_k}} = \frac{1}{\sqrt{\lambda}} \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{C_k}}$$

Sledi:

$$\sqrt{\lambda} = \frac{1}{n} \sum_{k=1}^K \frac{W_k \sigma_k}{\sqrt{C_k}}$$

Končno sledi:

$$n_k = \frac{n W_k \sigma_k}{\sqrt{C_k} \sum_{i=1}^K \frac{W_i \sigma_i}{\sqrt{C_i}}}$$

c)

V tem primeru želimo minimizirati stroške. Torej bomo zapisali vezani ekstrem za stroške raziskave, pri pogoju  $var(\bar{X}_s) = \sum_{k=1}^K \frac{W_k^2 \sigma_k^2}{n_k}$ . Torej:

$$L(n_1, \dots, n_K, \lambda) = C_0 + \sum_{k=1}^K C_k n_k + \lambda \left( \sum_{k=1}^K \frac{W_k^2 \sigma_k^2}{n_k} - var(\bar{X}_s) \right)$$

Postopamo kot v prejšnjih točkah:

$$\frac{\partial L}{\partial n_i} = C_i - \lambda \frac{W_i^2 \sigma_i^2}{n_i^2} = 0,$$

za  $i = 1, 2, \dots, K$ .

Računamo:

$$n_i = \sqrt{\frac{\lambda}{C_i}} W_i \sigma_i.$$

$$n = \sum_{i=1}^K n_i = \sum_{i=1}^K \sqrt{\frac{\lambda}{C_i}} W_i \sigma_i = \sqrt{\lambda} \sum_{i=1}^K \sqrt{\frac{1}{C_i}} W_i \sigma_i$$

$$\sqrt{\lambda} = \frac{n}{\sum_{i=1}^K \sqrt{\frac{1}{C_i}} W_i \sigma_i}$$

Torej:

$$n_i = \frac{n}{\sqrt{C_i} \sum_{j=1}^K \sqrt{\frac{1}{C_j}} W_j \sigma_j} W_i \sigma_i.$$

### 3.NALOGA

a)

$$X \sim f(x, \alpha) = \begin{cases} \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}, & 0 < x < 1. \\ 0, & \text{sicer.} \end{cases}$$

Vemo:

$$E(X) = \frac{1}{3}, \text{var}(X) = \frac{2}{9(3\alpha+1)}.$$

Ker je:

$$\text{var}(X) = E(X^2) - E(X)^2,$$

sledi:

$$E(X^2) = \text{var}(X) + E(X)^2 = \frac{2}{9(3\alpha+1)} + \frac{1}{9} = \frac{\alpha+1}{3(3\alpha+1)}$$

$E(X^2)$  je drugi moment slučajne spremenljivke  $X$ , torej:

$$E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

Zgornji enačbi izenačimo in poračunamo  $\alpha$ :

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\alpha+1}{3(3\alpha+1)}$$

$$\frac{9\alpha+3}{n} \sum_{i=1}^n X_i^2 = \alpha+1$$

$$\frac{9\alpha}{n} \sum_{i=1}^n X_i^2 - \alpha = 1 - \frac{3}{n} \sum_{i=1}^n X_i^2$$

$$\alpha = \frac{1 - \frac{3}{n} \sum_{i=1}^n X_i^2}{\frac{9}{n} \sum_{i=1}^n X_i^2 - 1}$$

b)

$$f_X(x, \alpha) = \begin{cases} \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}, & 0 < x < 1. \\ 0, & \text{sicer.} \end{cases}$$

$$L_1(\alpha|x) = \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} x^{\alpha-1} (1-x)^{2\alpha-1}$$

$$L(\alpha|x_1, \dots, x_n) = L_1(\alpha|x_1) \cdot \dots \cdot L_1(\alpha|x_n) = \left( \frac{\Gamma(3\alpha)}{\Gamma(\alpha)\Gamma(2\alpha)} \right)^n x_1^{\alpha-1} \cdot \dots \cdot x_n^{\alpha-1} (1-x_1)^{2\alpha-1} \cdot \dots \cdot (1-x_n)^{2\alpha-1}$$

$$l(\alpha|x_1, \dots, x_n) = \ln(L(\alpha|x_1, \dots, x_n)) = l_1(\alpha|x_1) + \dots + l_1(\alpha|x_n)$$

$$l_1(\alpha|x) = \ln(L_1(\alpha|x)) = \ln(\Gamma(3\alpha)) - \ln(\Gamma(\alpha)) - \ln(\Gamma(2\alpha)) + (\alpha-1)\ln(x) + (2\alpha-1)\ln(1-x)$$

$$l(\alpha|x) =$$

$$\sum_{i=1}^n (\ln(\Gamma(3\alpha)) - \ln(\Gamma(\alpha)) - \ln(\Gamma(2\alpha)) + (\alpha-1)\ln(x_i) + (2\alpha-1)\ln(1-x_i))$$

$$\frac{\partial l}{\partial \alpha} = \sum_{i=1}^n \frac{1}{\Gamma(3\alpha)} \Gamma'(3\alpha) 3 - \frac{1}{\Gamma(\alpha)} \Gamma'(\alpha) - \frac{1}{\Gamma(2\alpha)} \Gamma'(2\alpha) 2 + \ln(x_i) + 2\ln(1-x_i)$$

$$\sum_{i=1}^n \frac{1}{\Gamma(3\alpha)} \Gamma'(3\alpha) 3 - \frac{1}{\Gamma(\alpha)} \Gamma'(\alpha) - \frac{1}{\Gamma(2\alpha)} \Gamma'(2\alpha) 2 = \ln\left(\frac{1}{x_i(1-x_i)}\right)$$

Cenilka obstaja, ko ima zgornja enačba rešitev.

c)

$$var(\hat{\alpha}) = \frac{1}{nI_1(\hat{\alpha})}.$$

$$I_1(\hat{\alpha}) = -E \left[ \frac{\partial^2 l_1(\alpha|x)}{\partial \alpha^2} \right]$$

$$\begin{aligned} \frac{\partial^2 l_1(\alpha|x)}{\partial \alpha^2} = & 3 \frac{\Gamma''(3\alpha)\Gamma(3\alpha) - \Gamma'(3\alpha)^2}{\Gamma(3\alpha)^2} - \frac{\Gamma''(\alpha)\Gamma(\alpha) - \Gamma'(\alpha)^2}{\Gamma(\alpha)^2} - 2 \frac{\Gamma''(2\alpha)\Gamma(2\alpha) - \Gamma'(2\alpha)^2}{\Gamma(2\alpha)^2} \\ var(\hat{\alpha}) = & \frac{1}{n} \frac{1}{3 \frac{\Gamma''(3\alpha)\Gamma(3\alpha) - \Gamma'(3\alpha)^2}{\Gamma(3\alpha)^2} - \frac{\Gamma''(\alpha)\Gamma(\alpha) - \Gamma'(\alpha)^2}{\Gamma(\alpha)^2} - 2 \frac{\Gamma''(2\alpha)\Gamma(2\alpha) - \Gamma'(2\alpha)^2}{\Gamma(2\alpha)^2}} \end{aligned}$$

## 4. NALOGA

Za reševanje te naloge, sem si pomagala s knjigo *John A. Rice: Mathematical Statistic and Data Analysis*. Iz poglavja 9.5, na strani 341, izvemo, da če imamo model, kjer so verjetnosti vektorsko porazdeljene in imamo opis za hipotezo  $H_0$ , kjer je  $p = p(\theta)$ , kjer je  $\theta$  neznan, je števec za verjetnostno funkcijo enak:

$$\max_{p \in \omega_0} \left( \frac{n!}{x_1! \dots x_m!} \right) p_1(\theta)^{x_1} \dots p_m(\theta)^{x_m},$$

kjer so  $x_i$  opazovane vrednosti v  $m$  celicah. Maksimum bo dosežen pri:

$$\hat{p}_i = \frac{x_i}{n}.$$

Razmerje verjetij je tako enako:

$$\Lambda = \frac{\frac{n!}{x_1! \dots x_m!} p_1(\hat{\theta})^{x_1} \dots p_m(\hat{\theta})^{x_m}}{\frac{n!}{x_1! \dots x_m!} \hat{p}_1^{x_1} \dots \hat{p}_m^{x_m}}.$$

Poglejmo sedaj naš primer. Podatke imamo podane v razpredelnici za  $m = 0, 1, \dots, 12$ ,  $n = \# \text{ podatkov} = 6115$ . Oprazovane vrednosti  $x_1, \dots, x_{12}$  prebermo iz drugega stolpca v tabeli. Računamo po postopku opisanem zgoraj:

$$\max \left( \frac{6115!}{7!45!181! \dots 24!3!} \right) p_1^7 p_2^{45} \dots p_{12}^3$$

Maksimum je torej dosežen pri:

$$\hat{p}_1 = \frac{7}{6115}, \hat{p}_2 = \frac{45}{6115}, \dots, \hat{p}_{12} = \frac{3}{6115},$$

Poračunati moramo še imenovalca ulomka, da bomo dobili razmerje verjetij. Testirati želimo hipotezo, da je število moških potomcev, ki se rodijo v družini z 12 otroci, porazdeljeno binomsko  $\text{Bin}(12, p)$ . Torej je verjetnostna funkcija  $L$  enaka:

$$L = \left( \frac{6115!}{7!45!181! \dots 24!3!} \right) ((1-p)^{12})^7 (2p(1-p)^{11})^{45} \dots (p^{12})^3.$$

Izraz logaritmiramo in odvajamo po  $p$ , izračunamo maksimum.

$$\frac{\partial l}{\partial p} = 0.$$

Po krajšem izračunu dobimo:

$$\frac{35280}{p} = \frac{38100}{1-p}$$

Tako dobimo:

$$\hat{p} = \frac{35280}{73380} = 0.4807849550286182.$$

Torej po Wilkinsovem izreku zapišemo:

$$\lambda = 2\ln(\Lambda) = 2l(\hat{p}_0, \dots, \hat{p}_{12}) - 2l(\hat{p})$$

Vstavimo zgoraj poračunane vrednosti:

$$2(7\ln(\hat{p}_1) + 45\ln(\hat{p}_2) \cdots 3\ln(\hat{p}_{12})) - 2(7 * 12\ln(1 - \hat{p}) + 45(\ln(12\hat{p}) + 11\ln(1 - \hat{p})) + \cdots + 3 * 12\ln(\hat{p}))$$

Ko vstavimo podatke dobimo:

$$\lambda = 97.0065.$$

Wilksov izrek nam pove, da bomo hipotezo zavrnili, če je  $\lambda > \chi^2_{1-\alpha}(\dim\Omega - \dim\Omega_0)$ . Dimenziji prostorov sta očitni:  $\dim\Omega - \dim\Omega_0 = 12 - 1 = 11$ . Testiramo za  $\alpha = 0.01$  in  $\alpha = 0.05$ . Iz tabele preberemo vrednosti in dobimo:

$$\chi^2_{0.99}(11) = 19.68, \chi^2_{0.95}(11) = 24.72.$$

Vidimo, da sta vrednosti v obeh primerih manjši od  $\lambda$ , zato hipotezo v obeh primerih zavrnemo.

Model bi lahko bil napačen iz več razlogov. Eden bi bil naprimer, da nismo upoštevali vsa rojstva, vendar le preživele otroke. Lahko, da smo zbrali podatke v različnih zgodovinskih obdobjih, katera vplivajo na rojstva otrok (vojna in podobno).

## 5. NALOGA

### Ocen po metodi največjega verjetja

Da bomo vedeli kako so porazdeljeni  $Y_i$ -ji, poračunamo njihovo pričakovano vrednost in varjanco.

$$E(Y_i) = E(\beta_0 + \beta_1 x_i + \epsilon_i) = \beta_0 + \beta_1 x_1$$

$$\text{var}(Y_i) = \sigma^2$$

Torej so  $Y_i$  porazdeljeni  $N(\beta_0 + \beta_1 x_1, \sigma^2)$ . Dobimo:

$$L_1 = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}}$$

Verjetnostna funkcija je sestavljena iz produktov porazdelitvenih funkcij. Torej dobimo:

$$\log(L) = -n\log(\sigma) - \frac{n}{2}\log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

. Najprej poračunamo za prvi parameter  $\beta_0$ . Enačbo odvajamo po  $\beta_0$  in enačimo z 0.



$$\begin{aligned}\frac{\partial}{\partial \beta_0} \log(L) &= \frac{\partial}{\partial \beta_0} \left( -n \log(\sigma) - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right) = \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)\end{aligned}$$

Dobimo:

$$\sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

Sledi:

$$\sum_{i=1}^n y_i - n\beta_0 - \beta_1 \sum_{i=1}^n x_i = 0$$

Torej je končni rezultat enak:

$$\beta_0 = \frac{1}{n} \left( \sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right).$$

Postopek ponovimo za drugi parameter  $\beta_1$ :

$$\begin{aligned}\frac{\partial}{\partial \beta_1} \log(L) &= \frac{\partial}{\partial \beta_1} \left( -n \log(\sigma) - \frac{n}{2} \log(2\pi) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \right) = \\ &= \frac{1}{\sigma^2} \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)\end{aligned}$$

Dobimo:

$$\sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0.$$

Sledi:

$$\sum_{i=1}^n x_i y_i - \beta_0 \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 = 0.$$

Vstavimo vrednost za  $\beta_0$ :

$$\begin{aligned}\sum_{i=1}^n x_i y_i - \frac{1}{n} \left( \sum_{i=1}^n y_i - \beta_1 \sum_{i=1}^n x_i \right) \sum_{i=1}^n x_i - \beta_1 \sum_{i=1}^n x_i^2 &= 0. \\ \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i - \beta_1 \left( -\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i + \sum_{i=1}^n x_i^2 \right) &= 0.\end{aligned}$$

Torej je končni rezultat enak:

$$\beta_1 = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{-\frac{1}{n} \sum_{i=1}^n x_i \sum_{i=1}^n x_i + \sum_{i=1}^n x_i^2}$$

Oziroma:

$$\beta_1 = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}$$

Vstavimo še za  $\beta_0$ :

$$\beta_o = \frac{1}{n} \left( \sum_{i=1}^n y_i - \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \sum_{i=1}^n x_i \right).$$

$$\beta_o = \frac{1}{n} \left( \sum_{i=1}^n y_i - \frac{n \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i - \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \right).$$

$$\beta_o = \frac{1}{n} \frac{n \sum_{i=1}^n y_i \sum_{i=1}^n x_i^2 - \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i - n \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i + \sum_{i=1}^n y_i \sum_{i=1}^n x_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}.$$

Končni rezultat:

$$\beta_o = \frac{\sum_{i=1}^n y_i \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i y_i \sum_{i=1}^n x_i}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i}.$$

### Ocena po metodi najmanjših kvadratov

Ker so šumi  $\epsilon_i$  neodvisni za vsak  $i = 1, 2, \dots, n$  in  $\epsilon_i \sim N(0, \sigma^2)$  lahko uporabimo izrek Gauss-Markova za ocene parametrov  $\beta_0$  in  $\beta_1$ . Imamo:

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Po izreku Gauss-Markova vemo da je najboljša cenilka za  $\beta = (X^T X)^{-1} X^T Y$ . Računamo:

$$\begin{aligned} & \left( \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & \cdots & 1 \\ x_1 & \cdots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \\ & = \left( \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \right)^{-1} \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{bmatrix} = \\ & = \frac{1}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \begin{bmatrix} \sum_{i=1}^n x_i^2 & - \sum_{i=1}^n x_i \\ - \sum_{i=1}^n x_i & n \end{bmatrix} \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \end{bmatrix} = \\ & = \frac{1}{n \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \sum_{i=1}^n x_i} \begin{bmatrix} \sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i - \sum_{i=1}^n x_i \sum_{i=1}^n x_i y_i \\ - \sum_{i=1}^n x_i \sum_{i=1}^n y_i + n \sum_{i=1}^n x_i y_i \end{bmatrix} \end{aligned}$$

Zgornjo vrstico primerjamo z  $\beta_0$ , ki smo jo dobili po metodi največjega verjetja, spodnjo pa z  $\beta_1$ . Vidimo, da sta enaki.